Guia Definitivo: O Modelo CRISP-DM

O roteiro metodológico completo para o ciclo de vida de projetos em Ciência de Dados.

Disciplina: Ciência de Dados e Aprendizagem de Máquina | A1
Docente: Profa. Kadidja Valéria

Gemini Notebook

O Padrão da Indústria para Mineração de Dados

CR (Cross-Industry): Padrão aplicável a vários segmentos de mercado.

SP (Standard Process): Processo padronizado e estruturado.

DM (Data Mining): Focado em mineração de dados e análises preditivas.

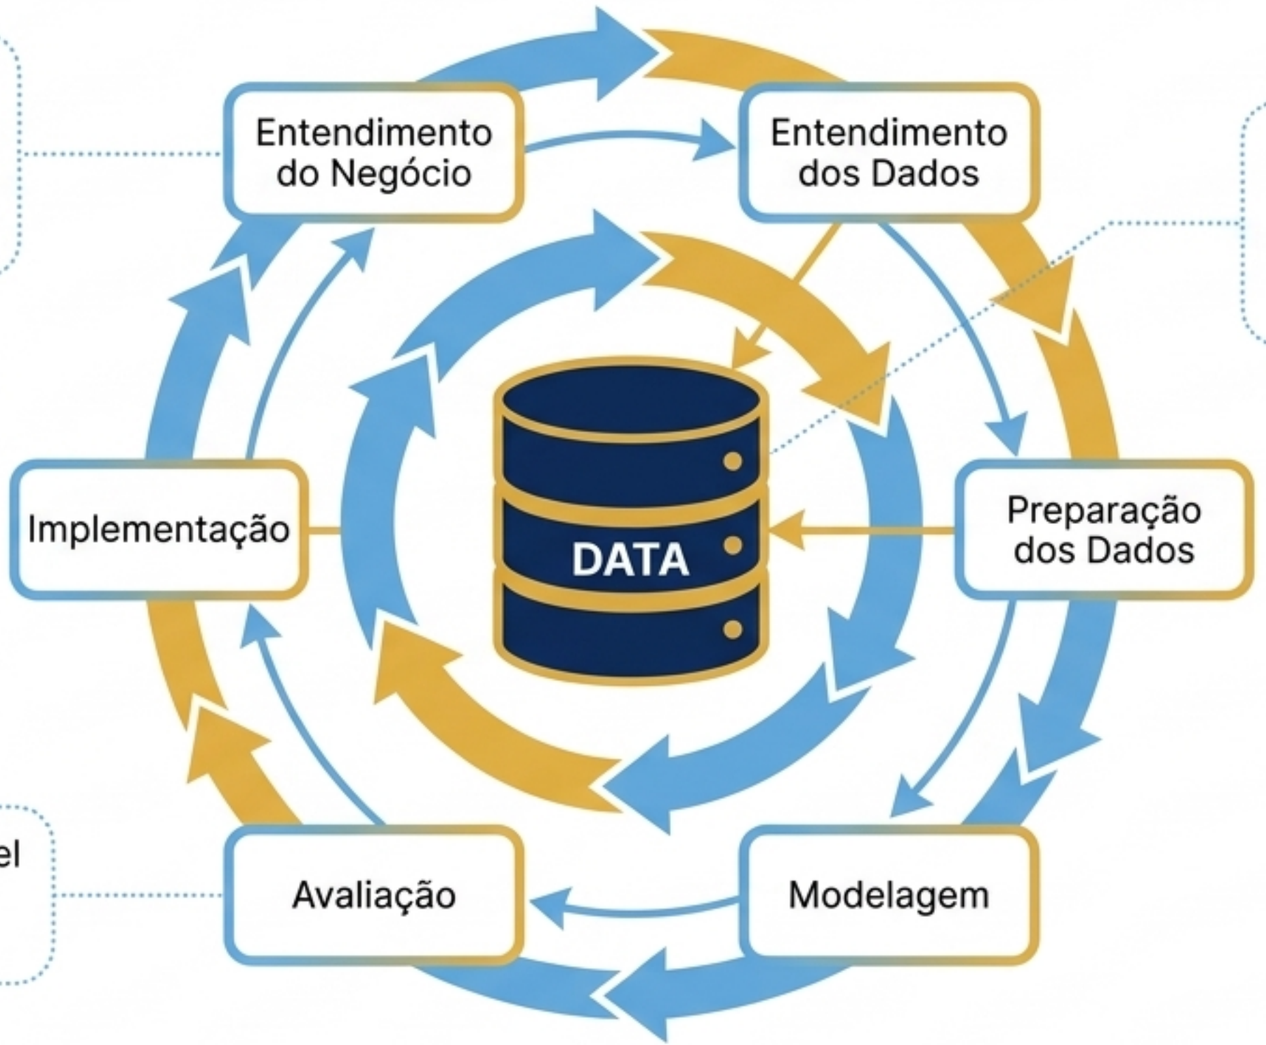
Como Metodologia:
Define fases típicas, tarefas exigidas e relacionamentos diretos entre equipes de negócios e técnicas.

Como Modelo de Processo:
Fornece uma visão do ciclo de vida completo, transformando problemas abstratos em roteiros acionáveis.

Gemini Notebook

A Jornada do Ciclo de Vida: O Motor Iterativo

Não-Linearidade: A sequência não é rígida. Fases interagem e retornam conforme novas descobertas.



Centralidade: O servidor de Dados é o eixo ao qual o entendimento e a preparação estão conectados.

Flexibilidade: Customizável de acordo com a necessidade do projeto.

Gemini Notebook

Fase 1: Entendimento do Negócio



OBJETIVO CENTRAL

Traduzir o problema de negócio em metas técnicas viáveis antes de investir recursos computacionais.

CHECKLIST DE EXECUÇÃO

- [ ] Determinar os objetivos de negócios e critérios de sucesso.
- [ ] Avaliar a situação (recursos, riscos, análise de custo-benefício).
- [ ] Determinar metas técnicas de mineração de dados.
- [ ] Produzir o Plano de Projeto.

CASO PRÁTICO: Varejo Eletrônico



Cenário: E-commerce perdendo espaço na Web; altos custos de aquisição.

Meta de Negócio: Aumentar vendas cruzadas em 10% e tempo no site.

Meta Técnica: Análise de cesta de compras (itens relacionados) e análise de sequência (navegação).

Gemini Notebook

Fase 2: Entendimento dos Dados



OBJETIVO CENTRAL

Acessar, quantificar e qualificar a matéria-prima disponível para evitar falhas imprevistas na modelagem.

CHECKLIST DE EXECUÇÃO

- ☐ Coletar dados iniciais (existentes, comprados ou adicionais).
- ☐ Descrever quantidade e qualidade (volume, tipos de valores, códigos).
- ☐ Explorar dados (gráficos, hipóteses iniciais).
- ☐ Verificar qualidade (erros, dados omissos, inconsistências de medição).

CASO PRÁTICO: Varejo Eletrônico

Fontes: Logs da Web (navegação brutos), BD de Compras (transações), BD de Produtos, BD de Clientes (cadastros incompletos).

Descobertas: Monitor de 119 polegadas (erro de digitação a corrigir). Questionários com respostas em branco.

Gemini Notebook

Fase 3: Preparação dos Dados



OBJETIVO CENTRAL

Transformar, limpar e empacotar dados brutos em um formato digerível pelos algoritmos. É a base do sucesso.

CHECKLIST DE EXECUÇÃO

Selecionar	Limpar	Construir	Integrar
(Filtrar)	(Tratar)	(Derivar)	(Mesclar)



CASO PRÁTICO: Varejo Eletrônico

Mesclar os logs da Web com o BD de clientes via ID.

Filtrar atributos confidenciais (cartão de crédito).

Criar o atributo: tempo entre eventos na sessão.



50% a 70% do tempo e esforço total do projeto é consumido exclusivamente nesta fase.

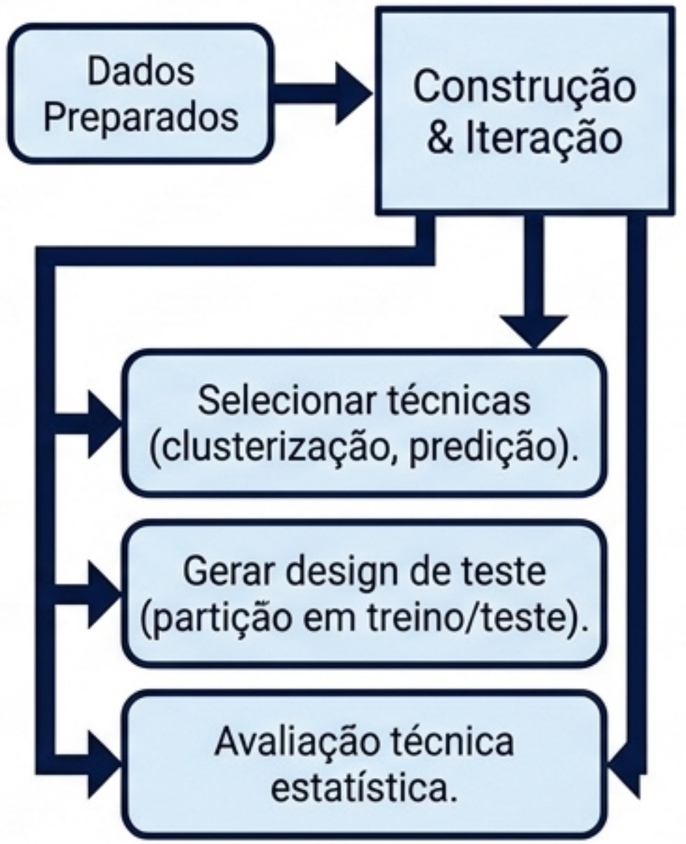
Gemini Notebook

Fase 4: Modelagem

OBJETIVO CENTRAL

Aplicar técnicas matemáticas, gerar designs de teste e iterar parâmetros para descobrir padrões de alto valor.

CHECKLIST DE EXECUÇÃO



CASO PRÁTICO: Varejo Eletrônico

Recomendações: Redes Kohonen e regras C5.0 gerando clusters de compra.

Navegação: Algoritmos de Sequência gerando caminhos de cliques dos usuários.

Gemini Notebook

Fase 5: Avaliação



OBJETIVO CENTRAL

Medir a eficácia dos modelos finais exclusivamente através da lente dos critérios de sucesso dos negócios definidos na Fase 1.

CHECKLIST

1. Avaliar se os resultados respondem à meta.
2. Revisar falhas no processo.
3. Determinar: Implementar ou iterar?

CASO PRÁTICO

- **Decisão** - Os modelos fazem sentido comercial.
- **Nova Pergunta** - Recomendações diferem para usuários não registrados; precisamos enriquecer a base.

Gemini Notebook

Fase 6: Implementação



OBJETIVO CENTRAL

Incorporar formalmente os modelos ao sistema da empresa ou utilizar as descobertas para mudar a estratégia.

ENTREGÁVEIS FINAIS

- Plano de Implementação (arquitetura).
- Plano de Monitoramento (obsolescência do modelo).
- Relatório e Apresentação Final.
- Revisão do Projeto (lições aprendidas).

CASO PRÁTICO: Varejo Eletrônico

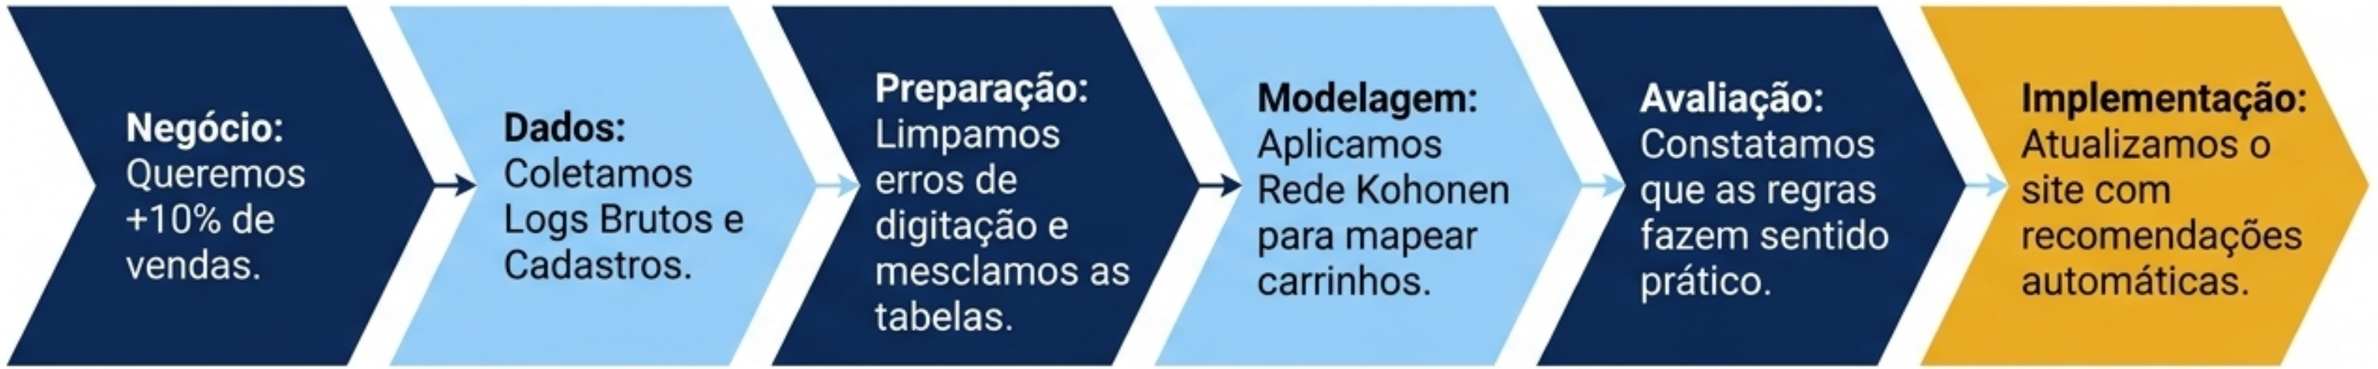
Desenvolvedores Web: Incorporam as regras de recomendação no site.

Especialistas de BD: Preparam a arquitetura para novos atributos.

Feedback: Alguns usuários antigos resistiram ao novo design do site.

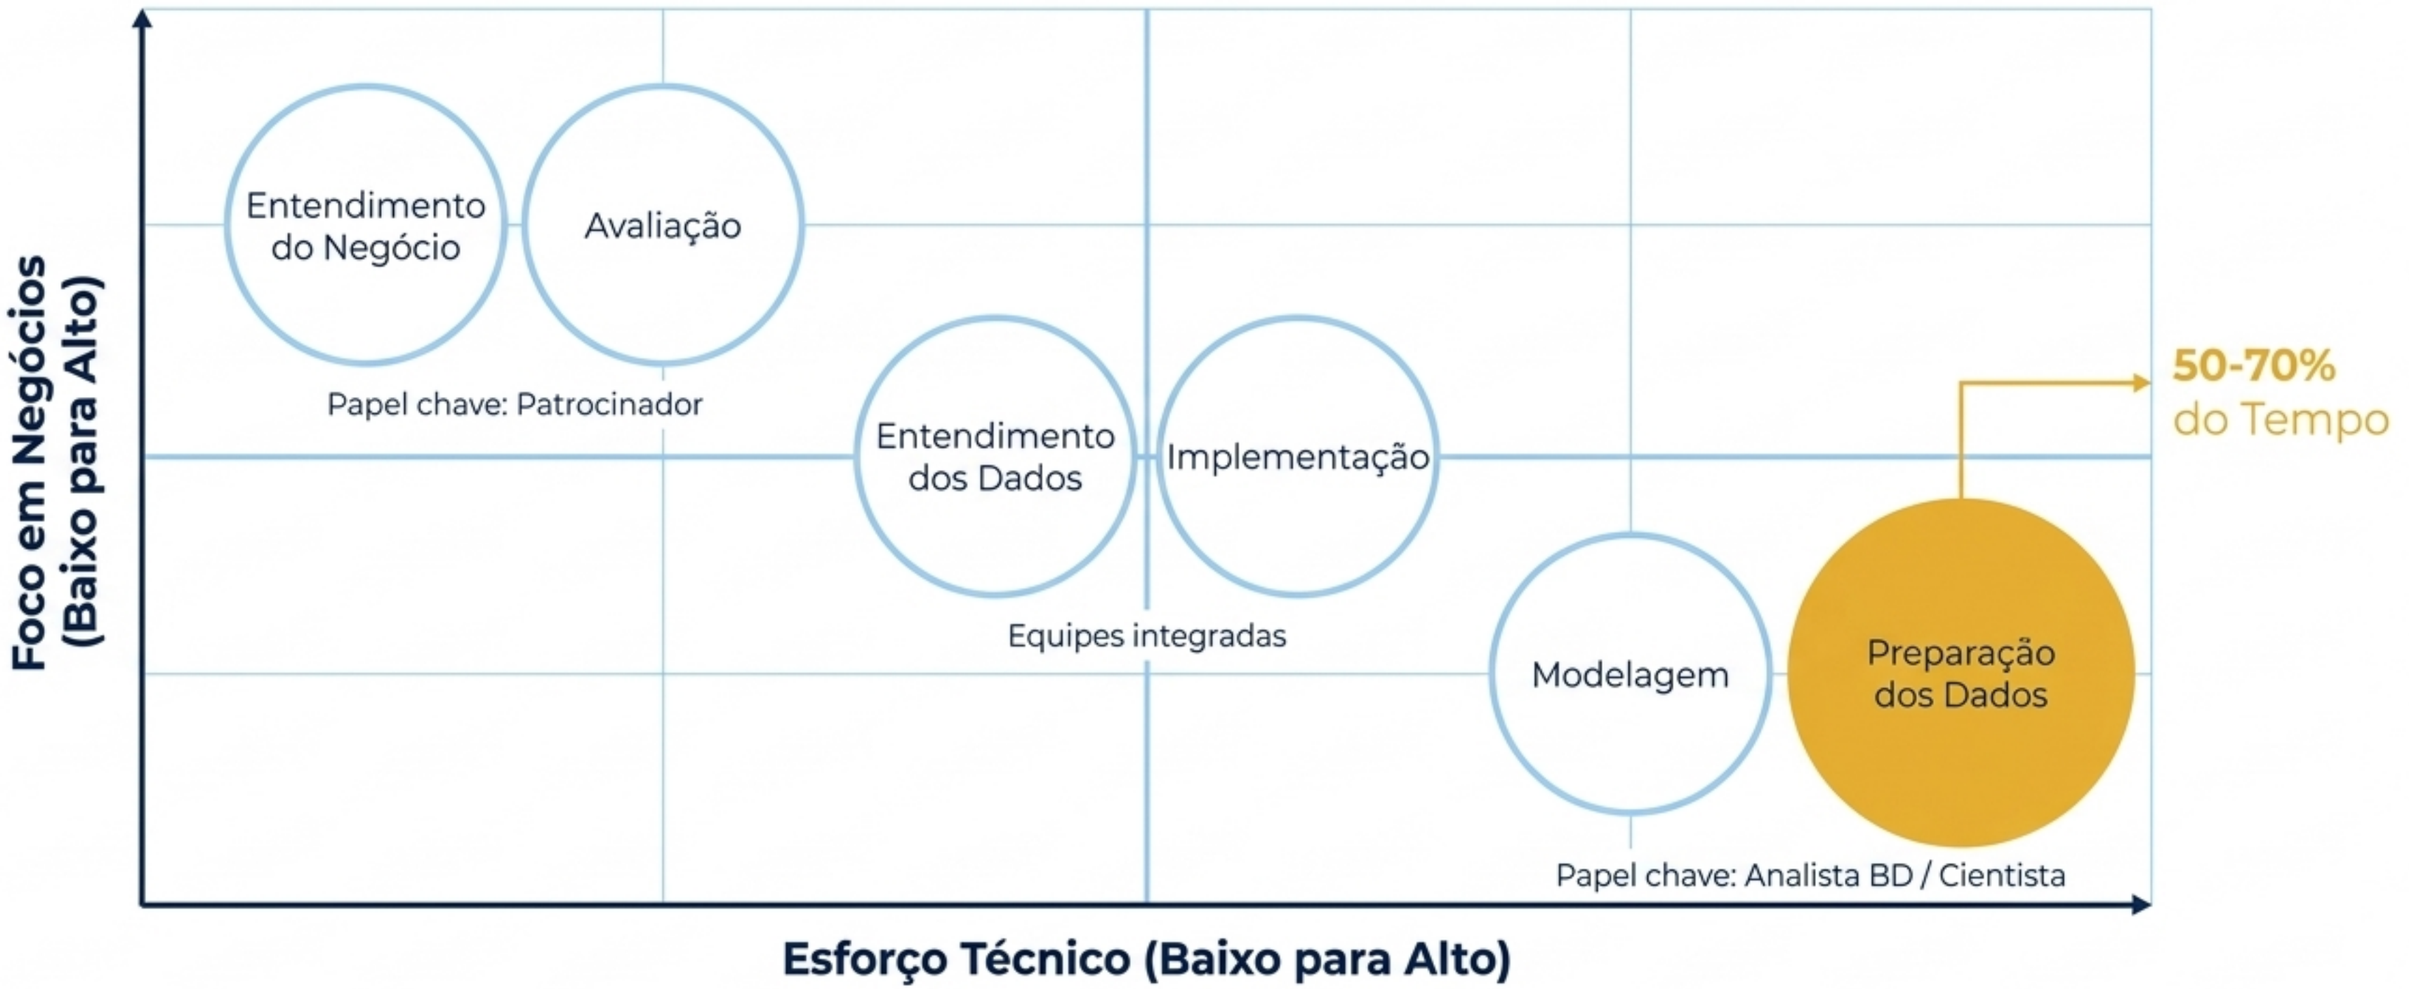
Gemini Notebook

Síntese Prática: O Fluxo do E-commerce



Gemini Notebook

A Matriz de Realidade do Projeto de Dados



Insight: O sucesso exige a comunicação perfeita entre áreas diametralmente opostas de expertise.

Gemini Notebook

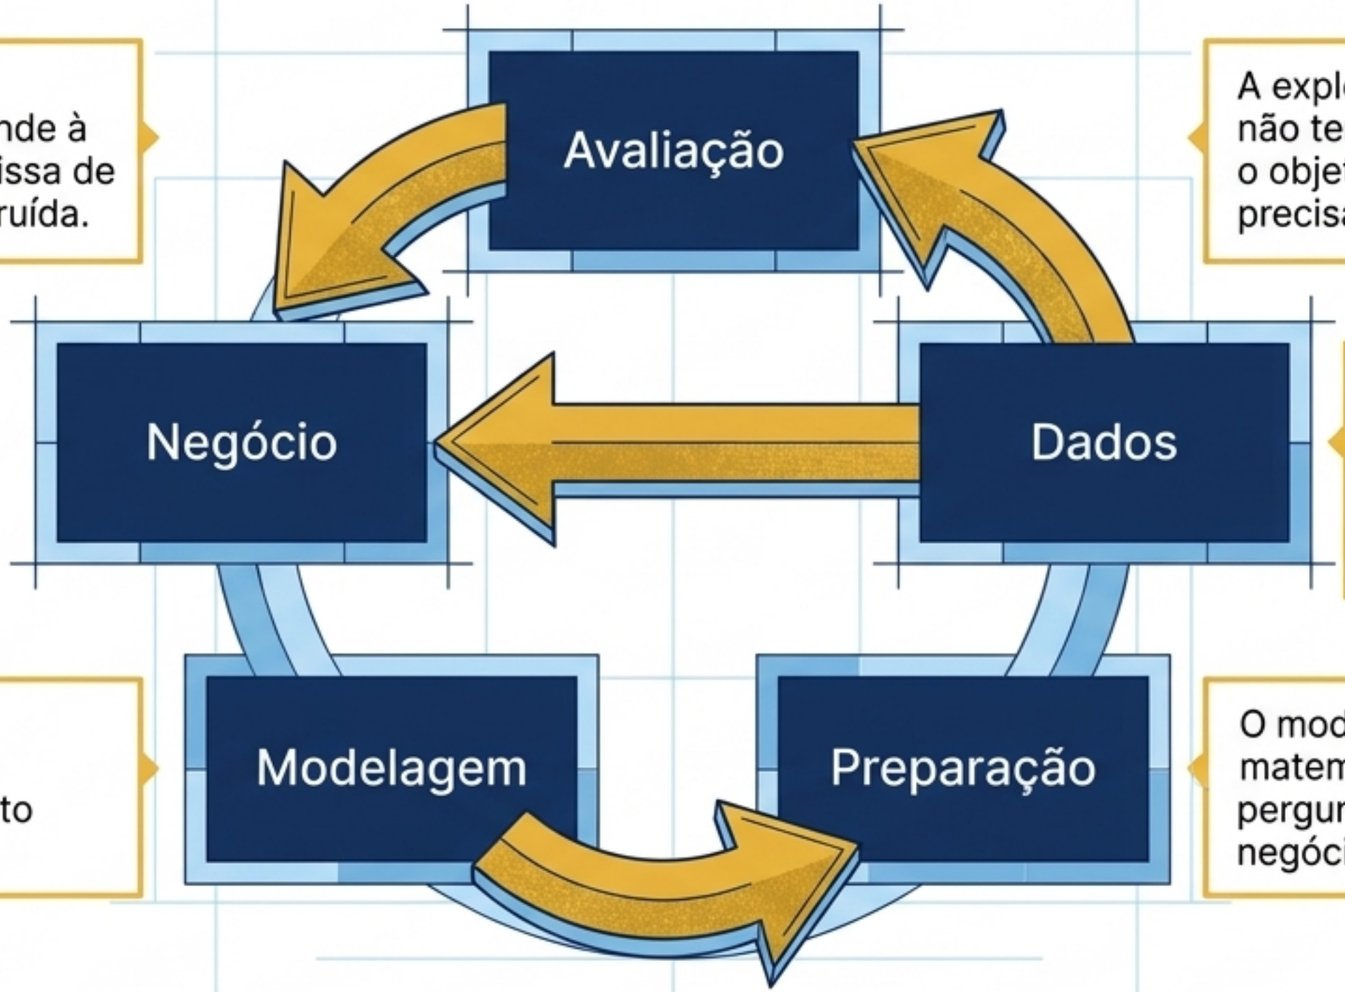
A Anatomia da Iteração: Por que o ciclo retorna?

Arrow 3

O modelo tem alta precisão matemática, mas não responde à pergunta financeira. A premissa de negócio precisa ser reconstruída.

Arrow 1

A exploração inicial revela que não temos dados suficientes para o objetivo planejado. O escopo precisa encolher.



Arrow 2

A exploração inicial revela que não temos dados suficientes para o objetivo planejado. O escopo precisa encolher.

Arrow 2

O algoritmo exige dados normalizados ou sem nulos, forçando um novo tratamento no BD.

Arrow 3

O modelo tem alta precisão matemática, mas não responde à pergunta financeira. A premissa de negócio precisa ser reconstruída.

No CRISP-DM, recuar não é falhar.
Cada volta no ciclo aumenta o poder e a precisão do projeto.

Gemini Notebook

Resumo Executivo: Checklist para o Sucesso

Comece pelo Negócio
Um algoritmo perfeito não salva uma premissa de negócios falha.

Respeite o Atrito
A preparação de dados consumirá mais da metade do projeto. Planeje-se para isso.

Abrace a Iteração
Execute modelos básicos cedo; avalie e retorne frequentemente para ajustar parâmetros e dados.

Mensure o Impacto
A avaliação final sempre deve usar os critérios de sucesso organizacionais, nunca apenas métricas estatísticas.

Documente a Jornada
O processo de implementação exige que as regras lógicas sejam traduzidas perfeitamente para as equipes de TI.

Gemini Notebook